

Stage 5 Video Call 条件性试验预案

版本: stage5-v1.0 | 作者: 项目外部分析者 | 资料截止: 2026-10-02 | 设计日期: 2026-10-03。

当前决策: 优先验证 H1 的自然使用与学习迁移问题; 先核真实权益增量与实施路线, 再决定是否实施公司试验。P1 尚未选定, 执行未就绪。 本文没有真实试验结果、样本量承诺、收益预测或公司审批。正式交付为本文生成的同版 Word/PDF, 埋点契约见 experiments/event_spec.csv, 决策摘要见 reports/decision_card.md。

1. 一个优先问题与可证伪机制

优先问题: 若目标账户确有尚未获得且可合法配置的 Lily 访问增量, 提供该访问能否在自然使用条件下, 改善日本市场、日语母语、中级英语学习者的延后未练情境口语迁移?

待检验路径是 “新增访问 → 降低开口摩擦 → 自愿有效表达 → 未练情境迁移”。拒绝、零使用、技术失败和课程挤出都是政策可能产生的结果。首通、通话数、词数、信心与续订分别回答过程或经营问题, 不能替代迁移能力, 也不能自动证明路径中的中介因果关系。

Stage2/2.1 的同任务市场线索与 Stage3/4 的特定完成者短期学习信号支持这个问题值得测; 它们没有确定自然全员效果、当前目标账户权益或盈利赢家。公司已披露 Super 扩展, 因而对照必须来自真实账户资格; 不能假设现行权益是 Max 独占。2026 Q2 股东信只支持公司推出陈述, 账户缺口与来源限制沿用 quant/stage4_final_delivery.md 和 quant/stage4_gap_register.csv。

2026 Q2 股东信

2. 公司试验的条件分支 只锁定一种真实增量

以下 C1 是待资格与权限核实的公司情境预案, 不是预选 P1 上线。只有公司确认存在 “原 Super、当前没有 Lily 访问且适合该课程” 的实际子集, 并确认可随机安排新增访问时点, 才能采用此分支。

要素	预定义与冻结条件
真实增量	从无 Lily 访问到获得公司已审定的一种标准访问权益。实际权益版本、限制、生效与恢复规则由授权方确认并登记; 本文不创造次数、分钟、试用期限或新的配额产品。
处理组 T	在随机分配后获得该新增访问。自然选择是否使用; 保留真实原权益与正常购买路径。配置失败和未使用仍留在原组。
对照组 C	保持分配前实际权益与正常购买路径。仅当新增访问的延后合法、符合承诺且不剥夺已购权益, 才允许作为对照; 延后时点须在方案冻结前批准。

要素	预定义与冻结条件
共同条件	测量邀请、补偿、随访和一般服务相同；访问说明是政策的一部分。不同提醒、训练指导或入口重设计会改变处理，须另行定义，不能混入本分支。
停止此定义	核实没有未覆盖子集、控制条件不合法或不能执行时，停止 C1。未观察到子集不等于证明不存在；也不改为临时增加任意配额来保住试验。

原 Free 试用 P2 与原 Max 权益变化继续保留为策略候选，当前不增加试验臂。无权益权限时可走第 9 节外部研究路线；这不会恢复公司权益试验资格。

3. 人群、分配与估计对象

资格在分配前核验：居住/市场范围、日语母语、英语课程、独立口语前测确认的中级范围、iOS/版本、个人账户、原 Super 套餐、实际 Lily 角色与访问、账单周期和续订机会。日语母语不代替日本居住，课程 B1.1 不代替口语水平，既有研究也不证明 iOS 或原 Super 身份。具体范围以真实资格分布和测量可行性冻结，不将未知填“合格”。

试验总体是符合资格、分配前完成知情同意与共同基线的去重个人账户。全员指全部随机账户，包含零使用者；不等于平台所有合格账户。记录招募分母、参与率与未参与原因；研究同意和测量可能改变使用，结论首先只适用于这批招募人群与测量条件。扩大到未参与账户另需代表性与外推证据。

建议以账户为随机化单位，按前测水平与已核实的计费/续订队列分层，层内 1:1 分配。1:1 是在两臂方差、成本接近时支持精度且便于审查的建议设计值，不是现行产品事实。排除家庭共享资格；在分配前处理已知重复账户。若实际共享或传播足以破坏独立处理，需要改变设计并重新规划样本，不能只在分析时忽略。

估计对象为 $\tau_L = E[Y(T) - Y(C)]$ ：在冻结的总体、权益版本和学习测量窗口下，**被分配新增访问**对延后迁移得分的全员平均效果。取消、转套餐、停用、控制组自行购买获得访问及实际配置失败均按原组继续追踪；记录交叉访问，不改分组、不按“成功使用”筛样。处理与随访、缺测必须围绕同一个估计对象设计。ICH E9(R1) 最终方法框架是所采用的事前定义原则来源，属于方法借鉴，未将本项目视为临床试验或声称 ICH 认可此方案。

ICH E9(R1) 最终方法框架

该效果包含入口、采用、剂量、失败和其他学习选择的共同变化；它不识别“同等练习剂量下 AI 比其他工具更好”。后者需要另一个对照任务研究，不能用只分析高频完成者或控制实际剂量来替换本方案。

4. 唯一 primary、测量窗口与必要护栏

唯一 primary KPI：延后未练情境口语迁移总分的全员、基线调整组间差 τ_L 。原始评分单位、总分算法与可接受最小增益 δ_L 尚未校准，现为 null。不把多个维度分别当 primary，也不在见到结果后选择最好看的量表。

测量由独立、对分组和使用剂量盲态的评审进行。前后测使用经试点验证的等难度平行任务，避免前测重复题目泄露后测；后测库不提供给练习系统或参与者，预设内容避免与已知课程及提示题库重合。自然开放对话仍可能产生类似情境，不能保证所有人从未接触。冻结任务库、语言水平范围、任务成功/自主表达等评分准则、总分合成、评审培训、双评与争议裁决规则。实际量表必须验证能作为连续总分解释、具有足够评审一致性及难度可比性；未通过时，不沿用下方连续指标公式，也不开始正式试验。

自然内容重合由独立评审按事前冻结的判别规则盲审。有效后测分数保留在原组 primary 分析，重合状态单列并按预设方案检查解释是否依赖练过内容；不得按处理后重合删人或临时换题选择较好结果。评分无效与内容重合分开，前者遵守既定缺测规则。若系统提前泄露后测库，或合理重合敏感度已无法支持未练情境解释，则测量/学习 Gate 不通过，只报告该固定任务得分的受限结果。实际重合可接受界限与审查动作需在正式分配前由测量试点冻结，当前未校准。

窗口	定义与冻结依据
H_pre 基线	分配前、同资格与课程阶段的共同前测和常规学习/账单基线；长度由历史波动、可比性与可用记录确定。
H_L 学习主窗口	同一权益版本的自然暴露期，加一个冻结的延后测量间隔。由匹配可行性试点、学习目标和任务等值性确定。延后不是取消权益或强制停练；期间继续自然使用也属于政策，不能解释成停练后的保持效应。
H_B 经营窗口	选择真实同 SKU/账单周期、可匹配续订时点的队列；两臂采用相同规则覆盖至少一个真实续订机会及该渠道退款/费用成熟期。根据真实续订日与成熟规则冻结结束日期。年付未到续订不作续订结果。

正式方案须在首次随机分配前填入上述日期、任务版本与成熟规则。学习与经营窗口可以不同，但各自两臂同口径；全部访问和成本计入相应观察期。没有任意“90 日”、年价折算、窗口外 LTV 或固定免费期。结果受该期限制，不外推多年收益。

指标角色	测量与用途	预设门槛
机制次要指标	资格→曝光→尝试→有效主动表达、重复使用；每账户分母包含已确认的零使用。有效表达需任务/质量准则，词数和分钟单列。	用于解释摩擦或迭代；不替代 primary，不把条件于使用的比较称因果中介效果。

指标角色	测量与用途	预设门槛
课程挤出护栏	原有课程完成与有效学习时间的原组全员差，比较同阶段基线；新增口语时间与总学习时间分开。	可接受损害界值由课程/教学责任人在冻结前依据匹配基线确定，当前 null。
质量与可靠性护栏	打断、转写/误纠、失败/重试/回退及投诉；以尝试/账户两种分母报告。	从实际历史服务标准与教学风险确认，当前 null；系统性伤害或权益配置错误可立即暂停。
经营与成本 Gate	同窗全员账单净贡献、退款/取消、两臂完整服务成本及增量投入；不是第二个学习 primary。	实际批准预算、贡献口径与商业准则冻结前确认，当前 null；无完整成本不通过扩张 Gate。

5. 样本量、MDE 与分析 有公式，暂无数字

建议主分析使用双侧 $\alpha=0.05$ ，目标 power $1-\beta=0.80$ ，1:1 分配；双侧检验同时允许发现损害，单一 primary 避免事后择优。以上均为建议的事前错误控制与资源权衡值，须由拟执行团队确认，不是 Duolingo 事实、既有研究参数或已校准最优值。

对于相等每臂观测数 n 、独立账户和近似连续得分，令 $\sigma_{T,res}^2$ 、 $\sigma_{C,res}^2$ 为预设基线调整后的匹配残差方差。两臂均值差方差为 $(\sigma_{T,res}^2 + \sigma_{C,res}^2)/n$ 。正态近似下：

$$MDE_0(n) \approx (Z_{1-\alpha/2} + Z_{1-\beta}) \sqrt{(\sigma_{T,res}^2 + \sigma_{C,res}^2)/n}$$

$$n_{obs} \approx \frac{(\sigma_{T,res}^2 + \sigma_{C,res}^2)(Z_{1-\alpha/2} + Z_{1-\beta})^2}{(\delta_A - \delta_L)^2}$$

这里 δ_L 是外部于正式结果确定的最小有意义增益， $\delta_A > \delta_L$ 是用于规划的目标真效应；第二式针对要求置信区间下界超过 δ_L 的学习 Gate。若只规划拒绝零效应，则把 δ_L 设为检验边界零，但该样本规划不能自动满足有意义增益 Gate。 δ_A 不是预测 uplift。固定 n 时可检测的有意义真效应约为 $\delta_L + MDE_0(n)$ ；未得到方差与 δ_L/δ_A ，不输出 N 或 MDE 数值。公式由 NIST 两样本标准误和 NIST 样本规划的 α/β /方差关系推导，属于规划近似，不是当前估计结果。

[NIST 两样本标准误](#)

[NIST 样本规划的 \$\alpha/\beta\$ /方差关系](#)

最低 baseline 包含同人群/权益增量/任务版本下的评分分布、残差方差、前后测相关、计费队列、测量到达率及缺测原因。若不能验证基线调整的精度收益，使用实际观测的未调整方差保守规划；不能借 DRR 完

成者效应、VOC 比例或 D 路径概率。教学与产品责任人从量表意义、可接受损害和投入决定 δ_L ，不能从主试验显著性倒推。

若信息损失可近似为匹配且独立的随访损失， $n_{\text{assign}} \approx \text{ceil}(n_{\text{obs}}/(1-r))$ 可作粗规划， r 来自匹配试点；两臂不对称或选择性缺测需重新评估信息量，该式不能消除偏差。资格规模、测量负担和预算必须容纳规划样本；任一不满足时，降级为可行性试点，不能保持“确认性试验”标签。出现群组随机化时须重新规划，不用账户公式直接报 N 。

主分析在原分组上采用预设 ANCOVA，以前测总分和随机化分层因素为协变量，对共同基线分布标准化组间差并采用稳健标准误；不调整使用次数、完成、后续套餐等处理后变量。模型式、标准化规则及缺测模型在冻结版本中写定。事前协变量调整可改善精度，但不能恢复随机化缺失或消除偏差；方法依据为 FDA 2023 协变量调整正式指南。

[FDA 2023 协变量调整正式指南](#)

分配后报告招募/随机/访问/后测流程、原组基线平衡、效应、95% CI、全部预设护栏及方案偏离。无实际结果时不填 CI。仅允许预设前测水平和真实续订队列的探索性交互，报告不确定性，不据小分群另宣布赢家。学习确认性分析只在成熟锁库后一次进行；日常检查限于服务故障、预算和资料质量，不根据反复窥视 p 值提前宣布成功。

6. 全员随访、缺测与最小数据契约

零使用者、未达到练习要求者、取消/转套餐者均邀请后测；测量便利与补偿不随练习完成度改变。失联、拒测、录音无效和数据管道失败分别记录为缺测；只有完整事件覆盖可确认“无尝试”时，行为计数才为零，**缺少日志或后测不是零表现**。

主分析以事前冻结、含原分组与基线信息的多重插补模型为计划，在给定已观测信息后缺测可忽略的 MAR 假设下估计全员效果。逐组公开缺测原因与比例，并对同一估计对象预设非随机缺测偏移/临界点分析：缺测者得分要改变到何种程度才使学习 Gate 翻转，结合量表范围和独立试点判断是否合理。完整案例比较仅作参考，不能替代 ITT；大比例或差异性缺测使结论依赖强假设时降级为“不足以支持扩张”。ICH E9(R1) 支持区分停用与缺测、尽量继续随访及围绕同一估计对象检查假设敏感性的原则。

[ICH E9\(R1\)](#)

埋点不是已存在的系统。event_spec.csv 列出请求契约：不可变原组与原套餐分母、资格快照、权益配置/曝光、基线、尝试与失败、有效表达、常规课程、盲态平行任务、随访缺测、完整账单退款费用、赠送/非赠送互斥服务账单及购买后调用、跨层曝光和预算。字段当前无观测值。

账单与服务必须按原组覆盖相同 H_B ，分别计算：

$$\Delta v_s = (\bar{m}_{T,s} - \bar{m}_{C,s}) - (\bar{c}_{T,s} - \bar{c}_{C,s})$$

m 扣退款及必要非 AI 费用、未扣 AI；现金或确认口径在冻结前选定。c 含对照已有服务、失败、重试、回退及购买后调用。升级与续订不能重复记一笔收入，赠送与非赠送标签互斥，账单和成本聚合以交易/请求唯一键去重。全员差不再乘采用率。缺必要观测时结果保持 null，既有标价不填净贡献。

该单层试验能识别目标原 Super 层在其处理下的直接差；**不能识别原 Max 的信息传播、降级及完整政策净值**。目标层潜在 Max 购买分流由本层完整账单体现，原 Max 降级需另有原 Max 的可识别政策曝光设计。未来若要总体扩张，另行批准有干扰范围依据的群组/分期设计；未知传播不设零。

7. 冻结清单与 Scale / Iterate / Stop

在查看任何正式结果前，由拟执行的产品、教学、实验、财务与数据责任人确认：真实 P0/增量与权限；总体/招募/随机化；实际权益配置；平行任务与总分校准；H_pre/H_L/H_B； δ_L/δ_A 、课程/质量护栏；匹配 baseline、N/MDE；缺测与分析计划；完整服务/固定投入预算；所采用的经营盈利或教学投资准则。所有目前未确认项是启动 Gate，不以空栏等同默认批准。

判断	未来团队采用的规则；当前均未发生
Scale：只扩到已验证范围	主效应 95% CI 下界达到事前有意义增益 δ_L ，合理缺测敏感度下结论不翻转；课程/质量护栏通过；完整增量投入在批准预算内；权限与部署总体可外推性通过。若以经营盈利批准，另需同窗完整经济差及部署 N/F 满足对应盈亏平衡；若以教学投资批准，须明确可承担的非盈利投入，不能称盈利。
Iterate：仍未支持扩张	机制指标有改善但 primary 未达到学习 Gate，或结果精度不足/测量失败可修复。先定位资格、入口、服务质量或量表问题，修改处理后重新冻结试验；不通过换 primary、删零使用或删失访者取得成功。
Stop / 暂停	已证实无真实增量或对照不可实施则停止此政策定义；充分精度下 primary 上界仍低于 δ_L ，停止当前处理的学习论证；课程/质量伤害、实际预算越界或配置/数据完整性异常则暂停并审查。效果不显著但区间很宽属于不确定，不自动判零效果。

全政策 Scale 还需要各受影响原套餐层的效果、传播识别、同曝光的部署人数 N_s 、真实新增固定费 F 和权限： $V = \sum_s (N_s \times \Delta v_s) - F$ 。单层正学习/经济信号只支持该范围内下一步，不能补成全公司赢家。未成熟账单、未测传播、无部署规模或预算时，保持“受限验证/待补证”。

8. 执行分步与停止点

- 核资格和路线**：以日期明确的授权资格汇总核真实 P0、未覆盖子集与操作权限。只能观察志愿账户时仅证明该账户存在，不估总体覆盖。无增量或权限不符合即停止公司执行路线。
- 测量与数据可行性试点**：验证平行任务/盲评、全员随访、账单/服务对账及常规课程指标；从匹配分布规划 N/MDE 和窗口。试点只解决可行性，不冒充商业效果；重大处理变化需重做规划。

3. **冻结后随机试验**：保存不可变分配登记，审核两臂配置和事件完整性；只做预设运行护栏检查，保留原组并安排成熟后测/账单锁库。
4. **一次正式决策审阅**：报告效应与 CI、缺测敏感度、学习/挤出、预算与经济范围；按第 7 节作条件判断，记录下一轮有限问题。

当前无法通过的具体环节：S4G01 资格与新增访问未核；S4G02 实施授权/可配置对照未取得；S4G03 自然全员迁移与评分资产未建立；S4G08 匹配方差、缺测、MDE 未取得；S4G04/05 真实账单与完整成本未取得；S4G06/07 传播、部署 N/F 未取得。原研究完整 PDF 访问限制 S4G10 保留，不继续追索来填新试验参数。本文可以完成设计交接，实际试验启动和 Scale 不能通过。

9. 无公司权限时的外部降级路线

若有已合法获得 Lily 访问的知情参与者，可先做同任务自然观察，验证自主表达、盲评新情境、测量可行性与零使用随访；这是所招募人群的观察研究。若预注册随机“邀请/鼓励自然使用”对照，可估计**邀请政策**的 ITT，不能称新增权益效果。若做相同练习时间的随机工具比较，则估计**规定剂量下的工具/任务学习效果**，不等同自然权益政策。

这些路线均要保留分配前同意、全员后测、等难度平行任务与招募局限；没有公司账单、完整服务成本及政策曝光，结果只进入学习/可行性证据，不填 m/c、续订 uplift 或公司收入模型。连可行参与者与测量资源也不存在时，停在本预案交接，不能用模拟用户填实证缺口。

10. 方法与版本记录

方法来源	版本/期间；核读日期	支持与限制
ICH E9(R1) 原始最终指南	2019-11-20 最终版；2026-10-03	借鉴事前估计对象、原组继续随访及缺测敏感度；不提供本产品效果或 δ 。
FDA 协变量调整正式指南	2023-05；2026-10-03	借鉴事前基线协变量调整原则；不提供评分有效性、缺测解决或本项目 power。
NIST 两样本检验、样本量规划	在线方法手册，无产品报告期；2026-10-03	提供标准误与 α/β /方差关系，本文据此推导规划公式；近似需匹配分布与设计验证。

方法建议是设计值，不列为 A/B 级产品事实。Stage4 公开/公司研究按其原有证据分层和局限使用；本阶段未增加产品数值、模拟经营参数或真实效果数据。

Stage Review

- **阶段与状态**：Stage5 v1.0，降级通过（条件性设计交接）；试验执行未就绪，产品效果与扩张未通过。

- **对应总纲板块：**09 Experiment Design、10 Decision Review；一个优先问题、一个 primary、分支条件与扩张规则。
- **本阶段决策问题：**下一项能识别 H1 自然学习迁移的验证是什么，哪些条件才允许权益试验与扩张？
- **本阶段产物：**experiments/test_plan.md（同版 Word/PDF 源稿）、experiments/event_spec.csv、reports/decision_card.md，stage5-v1.0。
- **交接对象与下一行动：**模拟产品/教学/实验/财务团队先核资格、权限与测量可行性，再冻结一个公司分支；未声称真实公司接收或批准。
- **数据/图表版本：**沿用 Stage4 v2.0 截止 2026-10-02 的证据与缺口；本阶段无真实实验表/图，无产品计算代码。
- **Findings：**① H1 优先问题可定义，但 P1 尚未选定；② 自然政策 primary 必须全员迁移与缺测敏感度；③ 单层试验与完整政策经济扩张须分别过 Gate。
- **Evidence：**A：Stage4 有限官方陈述及公司研究，保持完成者/资格局限；C：Stage2/2.1 同任务市场线索；设计：本预案的假设、公式及方法来源。无 D 经济数值。
- **Business meaning：**检验新增访问能否产生值得投入且不挤出课程的自然学习价值；经营差与预算独立核算。
- **Decision impact：**先核真实增量与路线，不预选 P1；公司不可实施时转限定估计对象的外部研究或停止执行。
- **Hypothesis status：**H1 特定完成者短期信号已观察，自然全员迁移待验证；C1 资格/权限待核；H3 实际净值未知。
- **Unknowns / fallback：**当前资格、实施权、评分资产、窗口、方差/MDE/N、护栏边界、账单/成本、传播/N/F 均未确认；按第 9 节降级，经济值保持 null。
- **Checks actually run：**独立设计复核与 CSV 契约检查已执行：20 项唯一记录、11 个完整元数据字段，均标未采集。实际 Word COM 导出同版 PDF 并逐页检查，修正自然内容重合处理和来源表排版；最终文件与校验见 experiments/stage5_final_validation.json。未运行用户试验、统计效果分析或上线监控。
- **Gate：**证据：条件性设计降级通过，产品效果未通过；业务：机制、学习/挤出与完整成本要求通过，实际预算/净值未通过；决策：设计顺序与停止点通过，资格/权限不满足启动；相关性：限定 Speaking/Video Call 扩张，通过。正式产物验收仅覆盖设计及文件，不将执行未就绪当作已验证效果。
- **Scope cut：**不扩 H2/Free 多臂、不设计任意额度、不追加泛论文/VOC、不复制 DRR 完成者效果、不造 N/uplift/CI、不执行权益更改、不宣称全政策 ROI。
- **Next stage input：**同版方案、事件契约与决策卡；Stage6 只展示证据边界与条件行动，不把它包装成真实试验结果或已上线监控。